



Master 1, Ingénieur Industriel en informatique

PROGRAMMATION SCIENTIFIQUE

Est-ce que la saison 2 de la série Netflix "One Piece" sera un succès ?

Auteur :

M. Hugo JAUMOTTE

Version du 1er juin 2026

Table des matières

1	Introduction	2
2	Langages de programmation et modélisation de l'outil de prédiction	2
3	Définition du succès	2
4	Préparation des données	3
5	Analyse exploratoire des données	4
5.1	Graphe du rating par épisode	4
5.2	Histogramme des notations par épisode	5
5.3	Corrélogramme des notations	6
5.4	Observations	6
6	Statistiques descriptives	7
7	Analyse structurelle de la série	7
8	Tests statistiques	7
9	Modélisation des séries temporelles	8
9.1	Prédictions simples	9
9.1.1	Naive forecasting	9
9.1.2	Average forecasting	9
9.1.3	Drift forecasting	10
9.2	Arima	10
9.2.1	Auto Arima	11
9.2.2	ARIMA(1,1,0)	11
9.2.3	ARIMA(1,1,1)	12
10	Evaluation des modèles	12
11	Prédictions	13
12	Conclusion	13

1 Introduction

L'objectif de ce projet est de définir si la prochaine saison de la série en live action One Piece, produite par Netflix sera un succès, le tout via la production d'une série temporelle.

Pour cela, il sera nécessaire de définir ce qu'est réellement un succès, d'avoir une bonne compréhension du dataset utilisé, puis de choisir les outils à utiliser pour créer un modèle de prédiction.

2 Langages de programmation et modélisation de l'outil de prédiction

Premièrement, il faut déterminer le seuil de succès et nettoyer et analyser le dataset. Cela passe notamment par l'analyse exploratoire des données, ainsi que par une série de statistiques descriptives. Cette première partie sera développée en R. L'avantage de ce langage est qu'il permet de Créer des graphiques, histogrammes et corrélogramme nativement en une ligne, il en est de même pour les statistiques descriptives.

Une fois cela fait, le plus gros du travail est de modéliser une série temporelle permettant de prédire le succès de la série. Cette partie, qui constitue en réalité la majeure partie du projet, sera réalisée en Julia. Le langage a l'avantage d'être plus performant que le R, il permet d'effectuer des tests statistiques, simplement via la librairie HypothesisTests. Des modèles de prédictions complexes peuvent également être modélisés facilement via ce dernier, comme il le sera détaillé plus tard. Finalement, je me sens plus confiant pour travailler sur cette partie en Julia, étant donnée que c'est le langage des deux que je maîtrise le plus.

3 Définition du succès

Le but du projet est de déterminer si la série sera un succès, or la condition précise de ce succès nous est laissée pour choix. J'ai décidé de me baser sur la note par épisode de la communauté sur le site IMDb. J'ai déterminé le threshold comme étant le 3e quartile de la notation par épisode. Si la moyenne de la notation pour la saison produite est supérieure à ce threshold, alors la nouvelle saison sera considérée comme un succès.

Après lancement du script R, on obtient un résultat de 8.1 pour le 3e quartile.

4 Préparation des données

Nous avons initialement 8 datasets du site IMDb fournis pour l'entraînement d'un modèle et la prédiction finale, mais ces derniers n'étaient pas à jour et n'avaient pas de données sur le live action One Piece. J'ai finalement utilisé les dataframes suivant : <https://datasets.imdbws.com/>. Il s'agit en réalité des mêmes données mises à jour.

Le dataset principal, `title.ratings.tsv.gz`, était un agrégat de données brutes contenant les ratings par épisodes des séries, mais également les ratings globaux mélangés. J'ai donc fait une jointure sur l'id d'épisode entre ce dataset et `title.episode.tsv.gz`, ce qui m'a ensuite permis de filtrer les données et de récupérer uniquement les données concernant les ratings par épisodes, utilisés pour le calcul du threshold. Plus tard, j'ai filtré les données pour récupérer uniquement celles concernant la série one Piece.

Voici le tableau contenant les données nécessaires à la prédiction de la série temporelle :


- `tconst` : id d'épisode IMDb
- `averageRating` : notation par épisode
- `globalEpisode` : numéro d'épisode

tconst	averageRating	globalEpisode
tt11748904	8.3	1
tt11758442	8.3	2
tt11758446	7.7	3
tt11758452	8.0	4
tt11758462	8.9	5
tt11758464	8.6	6
tt11758476	8.6	7
tt11758482	9.1	8
tt29137511	8.3	9
tt38079830	8.4	10
tt38079831	8.7	11
tt38079833	8.2	12
tt38079834	8.4	13
tt38079837	8.3	14
tt38079840	9.4	15
tt38752902	8.8	16


On voit qu'il n'y a que 16 épisodes actuellement, ce qui est un échantillon assez faible pour calculer une prédiction fiable et entraîner un modèle. On peut donc se permettre de douter de la qualité de la prédiction finale.

5 Analyse exploratoire des données

5.1 *Graphe du rating par épisode*




5.2 *Histogramme des notations par épisode*



Au vu de cet histogramme à 9 batonnets, on observe que la majorité des observations semblent être groupées autour de la moyenne, avec peu de données aux extrêmes, ce qui nous laisse penser à une distribution normale. Nous ne pouvons malgré tout pas en être certain, car le faible nombre de données ne nous permet pas réellement d'observer la distribution caractéristique en cloche des distributions gaussiennes.

5.3 Corrélogramme des notations



Pour la fonction d'autocorrélation, on observe un intervalle de confiance important de 0.5. A cause de cela, aucune autocorrélation ne peut être déclarée significativement différente de 0 avec certitude. cela est du au petit échantillons d'observation, on peut donc dire que les valeurs des autocorrélation observées sont différentes des autocorrélations réelles.

5.4 Observations

On constate une claire limitation due au manque de données d'observations, cela pourrait avoir un impact sur l'entraînement et le choix d'un modèle. Une stratégie pouvant être envisagée serait d'entraîner un modèle sur un ensemble d'autres données pour avoir des observation plus précises et pouvoir faire un choix plus éclairé, et seulement faire la prédiction finale sur le dataframe One Piece. Seulement, la license possède un place assez particulière avec déjà un manga et une série animée à succès, faisant que la manière dont elle est notée par les fans peut différer des séries traditionnelles, c'est pourquoi j'ai choisi d'entraîner un modèle sur les données du live action malgré tout.

6 Statistiques descriptives

Tableau de statistiques descriptives pour les notations par épisode :

moyenne	8.5
médiane	8.4
écart-type	0.4195235
maximum	9.4
minimum	7.7

On observe des notations assez proches, avec un écart-type, et donc une variation faible pour ces deux premières saisons. On voit également que la série est déjà plutôt bien accueillie par les fans, avec une moyenne et une médiane supérieures au threshold déjà.

7 Analyse structurelle de la série

Au regard des deux points précédents, on constate que la série évolue avec une trend qui semble stable, autour d'une moyenne, avec un bruit relativement faible. On n'observe pas réellement de saisonnalité, même si cela est difficile à observer sur 16 points. Même si on observe pas de lags au niveau du corrélogramme, on peut penser qu'il y a un lag de 1 ou de 2 au vu de la nature des données observées (si un épisode est bien, il est probable que celui d'après le soit aussi, et inversement).

Cette première observation pourrait laisser penser qu'un modèle arima pourrait convenir pour prédire cette série temporelle. Pour vérifier cela, nous allons procéder à une série de tests statistiques.

8 Tests statistiques

Maintenant, toujours dans l'objectif de définir quel serait le meilleur modèle, j'ai voulu procéder aux tests de ADF et au Ljung-Box test. Le premier sert à déterminer si une série temporelle est stable, stationnaire, ou non, alors que le deuxième sert lui à tester l'autocorrélation. Voici les différents résultats obtenus via le script en Julia :

Test ADF

Nombre de lags	Statistique ADF	p-valeur	Conclusion
1	0.4324	0.8089	Non stationnaire
1	-2.0869	0.2498	Non stationnaire
1	-2.5509	0.3030	Non stationnaire
2	-1.9087	0.3280	Non stationnaire
4	-1.8834	0.3399	Non stationnaire

D'après les résultats observés, on voit des p-stats toutes supérieures à 0,05. Les résultats suggèrent que la série n'est pas stationnaire. Toutefois, cette conclusion doit être nuancée en raison du très faible nombre d'observations

Test de Ljung-Box

Lag	Statistique Q	p-valeur	Conclusion
2	0.7387	0.6912	Pas d'autocorrélation
4	1.9863	0.7383	Pas d'autocorrélation
8	3.7942	0.8752	Pas d'autocorrélation

Pour le test de Ljung-Box, les résultats obtenus pour des lags de 2, 4 et 8 présentent tous une p-valeur supérieure à 0,05. Les résultats. Aucune autocorrélation significative n'est mise en évidence par ce test. Encore une fois, cela pourrait être dû au faible volume de données.


9 Modélisation des séries temporelles

Pour cette étape d'entraînement de modèle de prédiction, j'ai décidé de séparer le dataset en 50% pour l'entraînement, et 50% pour le test.

Dans un premier temps, j'ai modélisé les modèles les plus simples : naive forecasting, mean forecasting et drift. Seulement ces trois là, car la série ne semble pas présenter de saisonnalité. J'ai ensuite voulu modéliser ARIMA avec différents paramètres, dans l'objectif de les comparer ensuite, pour déterminer lequel est le meilleur.


9.1 Prédictions simples

9.1.1 Naive forecasting




La prédiction donne des notes à 9 pour les 8 épisodes, soit la dernière valeur du dataset de test.

9.1.2 Average forecasting



On voit ici que la ligne de prédiction est proche de la moyenne pour l'ensemble du dataset. Cette version semble donc bien meilleure que le naive forecasting, qui doit plus convenir en cas trend croissante ou décroissante, ce qui n'est pas le cas ici.

9.1.3 Drift forecasting



Ce modèle repose sur le fait de calculer un point en ajoutant au point précédant la valeur de la pente moyenne du dataset de test.

Ce modèle est le moins adapté des prédictions de bases, car elle n'est pas du tout stationnaire, on voit même que le dernier résultat dépasse les 10.

9.2 Arima

Arima est un outil de prédiction plus évolué que les modèles précédents, il se décompose en trois sous modèles différents :


- AR : il s'agit de la partie auto régressive du modèle, prenant en compte la corrélation entre une valeur et la valeur lui précédant.
- I : arima est un modèle adapté à la prédiction de séries temporelle stationnaires, c'est pour ça que le I (integrated) permettant de supprimer la tendance pour rendre stationnaire une série qui ne l'est pas existe.
- MA : Moving average. Là ou AR se base sur les prédictions précédentes pour prédire la série, MA se base sur les erreurs précédentes.

D'après cette description, et les données déjà analysées auparavant concernant la trend, la saisonnalité, le bruit, ... le modèle ARIMA(1,0,0) semble être le plus pertinent, mais dans l'optique d'obtenir le modèle le plus performant possible, j'en testerai plusieurs.

La librairie StateSpaceModels permet d'utiliser le modèle SARIMA pour la prédiction de séries temporelles facile en Julia. Ce modèle permet, en plus des argument classique liés à ARIMA, de rajouter trois autre facteurs définissant la saisonnalité de la série. En les définissant sur 0, on peut modéliser le ARIMMA standard.


9.2.1 Auto Arima

Dans un premier temps, j'ai voulu utiliser Auto-ARIMA, algorithme permettant de calculer les paramètres de ARIMA lui semblant les plus pertinents.




On voit que l'algorithme a calculé un ARIMA(1,0,0), donc tout comme je le pensais, il considère bien qu'il s'agit du modèle optimal pour l'algorithme. On voit qu'il présente des prédictions similaires, voir quasi identiques à celles obtenues par la mean prediction.

9.2.2 ARIMA(1,1,0)



9.2.3 ARIMA(1,1,1)



10 Evaluation des modèles

Pour cette étape, je vais comparer les données prédites avec les données réelles, pour chaque modèle, via deux tests différents :

- MAE : Il permet d'évaluer l'erreur moyenne au global, donc quel modèle fait le moins d'erreurs dans l'ensemble
- RSME : Il relève plus spécifiquement les grosses erreurs ciblées


Le modèle produisant les scores les plus faibles pour ces deux tests sera donc celui considéré comme étant le plus performant.

Modèle	MAE	RSME
Naive	0.6124999999999996	0.6528782428600293
Mean	0.27187499999999987	0.3911121961790505
Drift	1.051785714285713	1.0977365395230674
Auto-ARIMA	0.27187499999999987	0.3911121961790505
ARIMA(1,1,0)	0.3899803155878121	0.43545592184539983
ARIMA(1,1,1)	0.3899803155878121	0.43545592184539983

On constate clairement que la prédiction par la moyenne, ainsi que ARIMA(1,0,0) (Auto-ARIMA) ont exactement les mêmes résultats, en plus d'être les meilleurs modèles. Ici, je vais choisir ARIMA(1,0,0) comme modèle de prédiction finale, car il offre une modélisation statistique plus générale et potentiellement plus robuste sur des séries de plus grande taille que la prédiction par la moyenne.

11 Prédictions

J'ai donc décidé de prédire les 8 prochains épisodes, ce qui correspond à la 3e saison (8 épisodes saison 1, 8 épisodes saison 2), avec le modèle ARIMA(1,0,0).



globalEpisode	averageRating
17	8.553799914471197
18	8.510526231049294
19	8.502920174890226
20	8.501583286376928
21	8.501348306400498
22	8.501307005
23	8.501299745410025
24	8.501298469

Cela nous donne une moyenne des notations par épisodes à 8.51, ce qui est supérieur à la valeur de seuil de 8,1, initialement fixée. On peut donc conclure que selon le modèle utilisé, la 3e saison de la série One Piece sera bien un succès.

12 Conclusion

Pour conclure, ce document retrace le procédé ayant permis de prédire le succès potentiel de la 3e saison du live action One Piece via l'entraînement et le test de différents modèles, ayant permis de choisir le modèle ARIMA(1,0,0) pour une prédiction finale optimale.

Cela nous a permis de définir que selon la méthode de prédiction utilisée, la prochaine saison de la série live action One Piece sur Netflix sera bien un succès.

Il faut cependant apporter de la nuance aux résultats observés en tenant compte des limitations de la démarche. Le dataset ayant servi de base pour la modélisation ne contenant que les données des premières saisons, soit 16

points, la qualité de la prédiction en a forcément été fortement impactée. Ensuite, le procédé de prédiction ne prenait en compte qu'un seul paramètre, là où la popularité de ce genre d'oeuvre me semblerait être impactée par toute une série de paramètres extérieurs autres que le rating. De plus, les données utilisées, à savoir les notations par épisodes, n'étaient probablement pas le meilleur indicateur de succès possible (définis l'appréciation, mais pas la quantité de personnes intéressée). Finalement, le seuil estimé pour le succès a été défini pour donner une finalité au rapport, mais pas un indicateur de succès réel.

Mots clés : Série temporelle, Julia, R, ARIMA, Prédiction

Département des Sciences et technologies
Haute école en Hainaut
8a Avenue Victor Maistriau
B-7000 Mons